Обучение без учителя. Иерархическая кластеризация. DBSCAN

otus.ru

REC Проверить, идет ли запись

Меня хорошо видно && слышно?

Тема вебинара

Обучение без учителя. Иерархическая кластеризация. DBSCAN

Мария Тихонова
LLM Research, SberAI
Tg: @mashkka_ds

Маршрут вебинара

- Как работает иерархическая кластеризация?
- DBSCAN
- Силуэтный коэффициент
- Практика

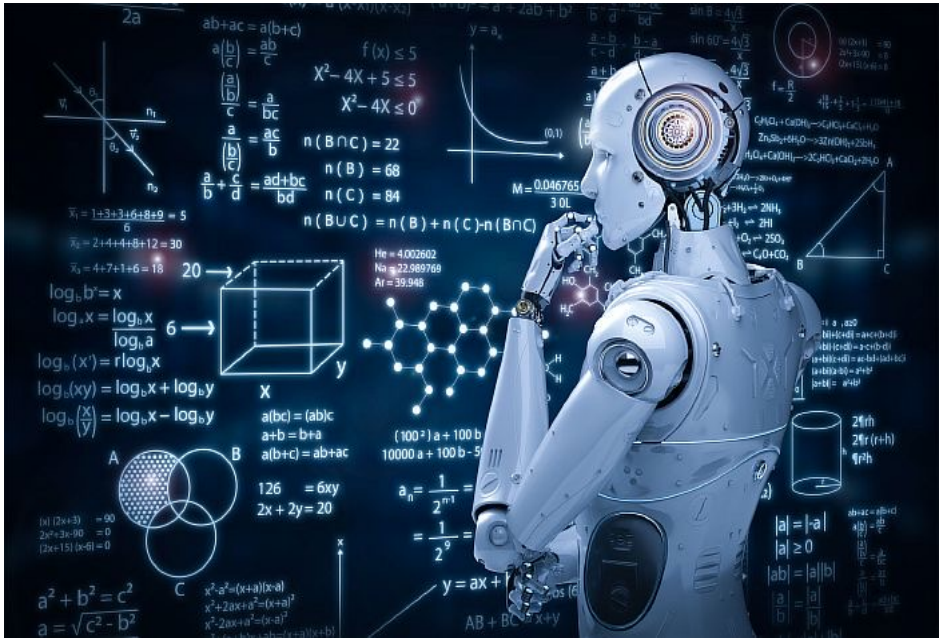

Иерархическая кластеризация

Иерархическая кластеризация

Agglomerative clustering
Агломеративная кластеризация

- Каждая точка – отдельный кластер
- На каждом шаге объединяются два ближайших кластера
- Объединение продолжается до тех пор, пока данные не сольются в один кластер

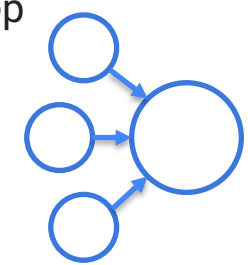

Divise clustering
Дивизивная кластеризация

- Все данные – один большой кластер
- На каждом шаге разделяется один из кластеров на две части
- Разделение продолжается до тех пор, пока кластеры не будут состоять из одной точки

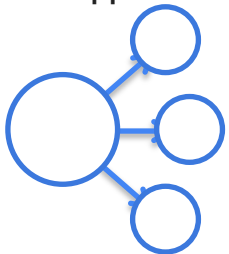

Agglomerative clustering

Объединение данных

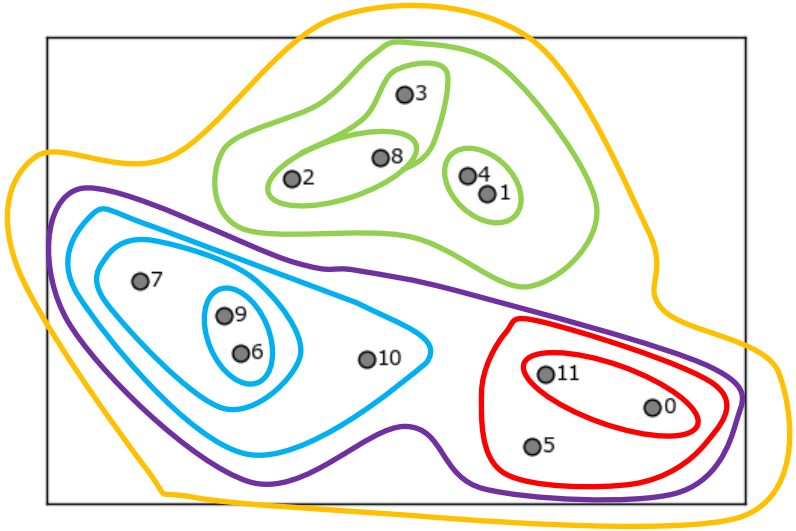

Как определить расстояние между кластерами?

Agglomerative clustering

Критерии связи (linkage)

Single linkage

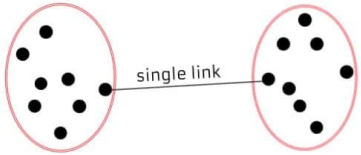

$$D(X,Y) = \min_{x \in X, y \in Y} d(x,y)$$

Complete linkage

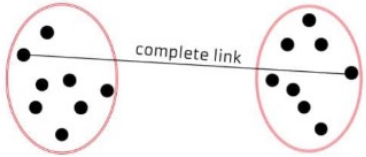

$$D(X,Y) = \max_{x \in X, y \in Y} d(x,y)$$

Average linkage

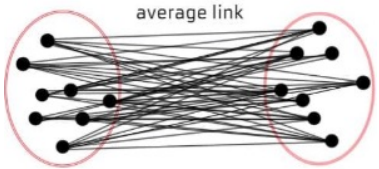

$$D(X,Y) = \frac{1}{|X| \cdot |Y|} \sum_{x \in X} \sum_{y \in Y} d(x,y)$$

Centroid linkage

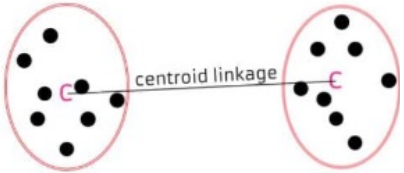

$$D(X,Y) = \|\mathbf{c}_x - \mathbf{c}_y\|$$

Ward linkage

В качестве расстояния между кластерами берётся прирост дисперсии, т.е. суммы квадратов расстояний объектов до центра кластера, получаемого в результате их объединения

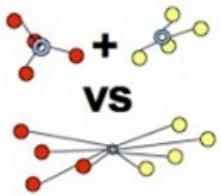

$$L_{Ward}(X,Y) = \sum_{x \in X} \sum_{y \in Y} \|x - y\|^2$$

https://aiaspirant.com/hierarchical-clustering/

Agglomerative clustering

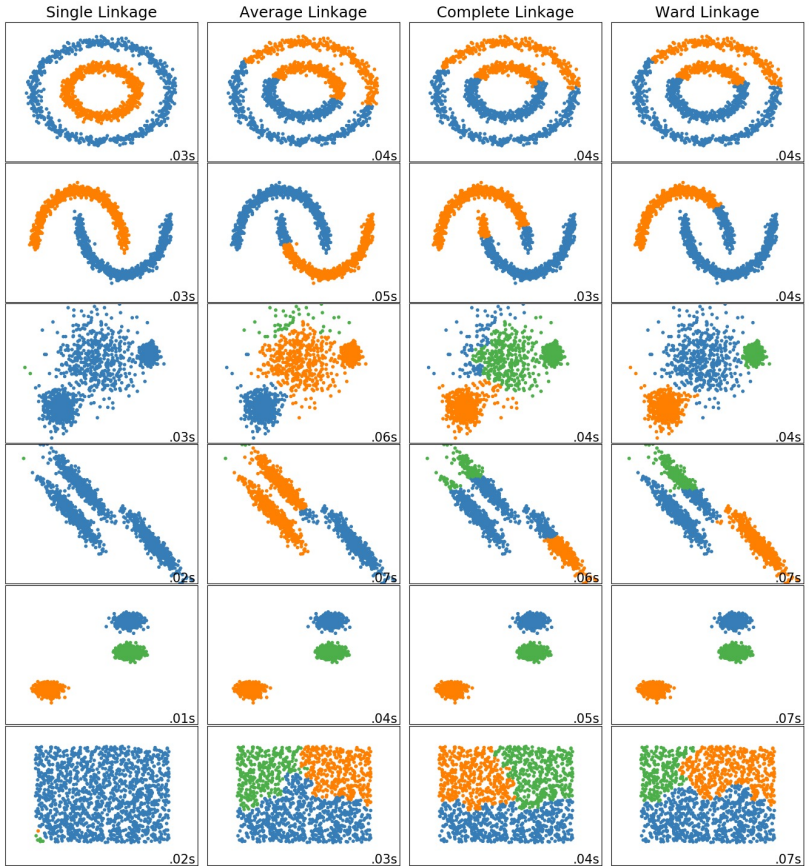

Agglomerative clustering

Выбор числа кластеров

Объединение данных

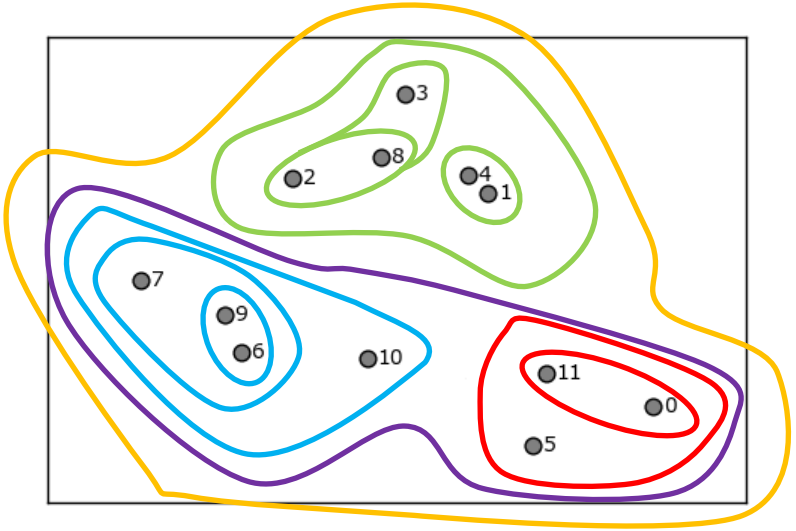

Дендрограмма

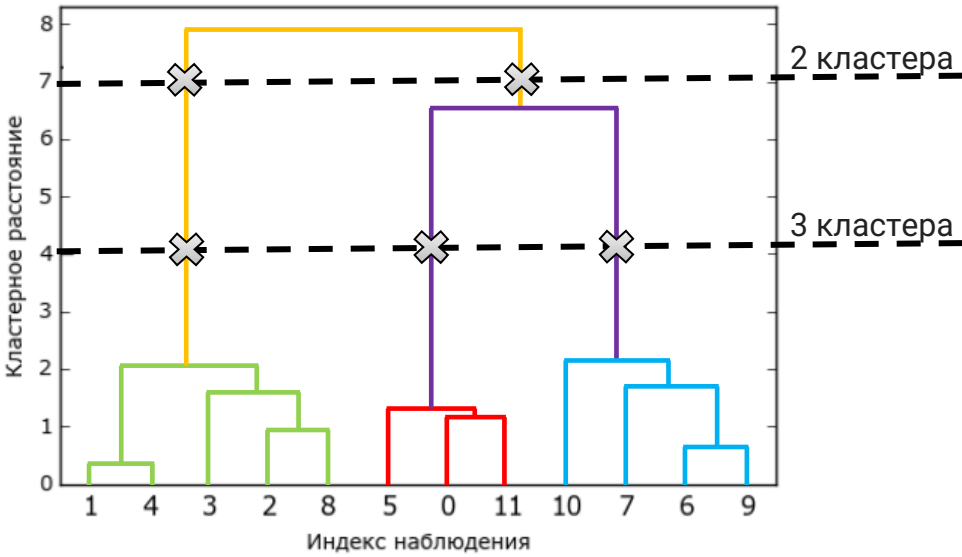

Плюсы и минусы иерархической кластеризации

Плюсы:

+ простая в реализации

+ иерархия кластеров

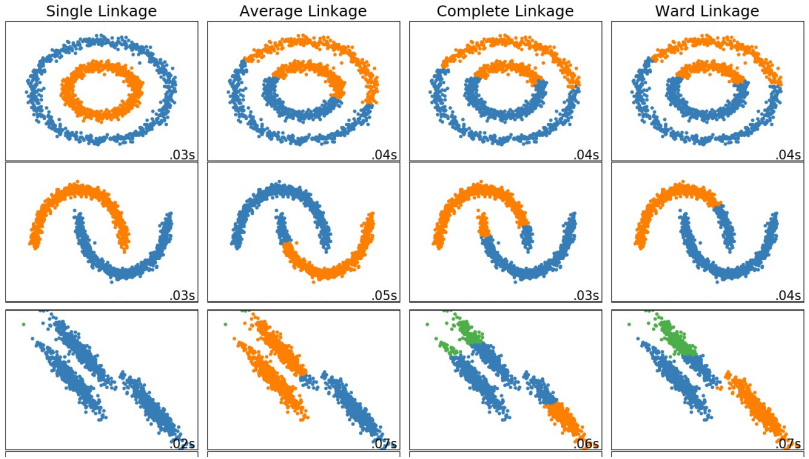

Минусы:

- вычислительные ресурсы и память

- не всегда может выделить сложные формы кластеров

- дендрограмма для небольшого объема данных

- выбор критериев связи

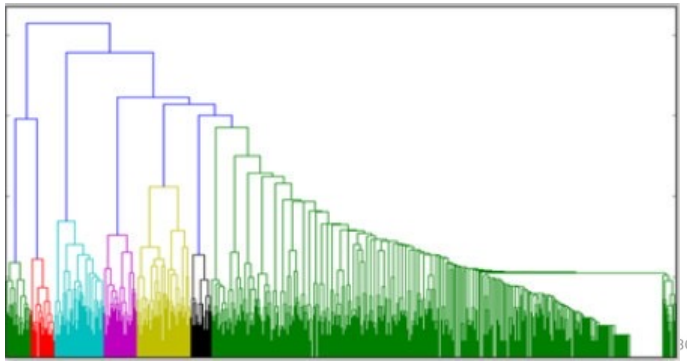

ЗОВАНИЕ

DBSCAN

DBSCAN

DBSCAN (density-based spatial clustering of applications with noise) - плотностный алгоритм кластеризации пространственных данных с присутствием шума

Параметры:

- **eps** – радиус окрестности
- **min_samples** – минимальное количество точек, которое должно находиться в окрестности *eps*

DBSCAN

DBSCAN (density-based spatial clustering of applications with noise) - плотностный алгоритм кластеризации пространственных данных с присутствием шума

Параметры:

- **eps** – радиус окрестности
- **min_samples** – минимальное количество точек, которое должно находиться в окрестности *eps*

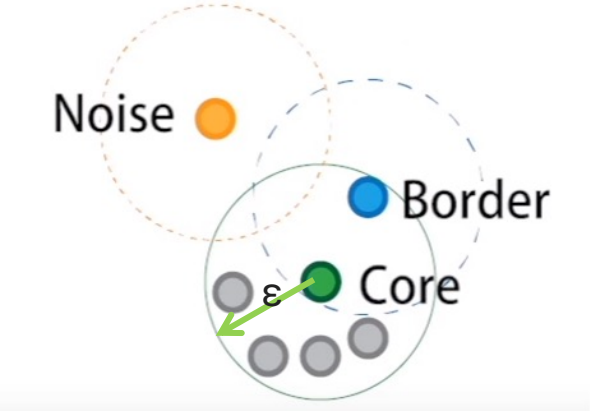

Типы точек:

- **core points (ядровые точки)** – в радиусе *eps* находится не менее *min_samples* точек
- **border points (пограничные точки)** – находятся в пределах радиуса окрестности ядровых точек, при этом в радиусе своей окрестности имеют меньше *min_samples* точек
- **noise points (шумовые точки)** – в радиусе окрестности *eps* меньше *min_samples* точек и не попадают в окрестность ядровых точек

DBSAN

Смотрим визуализацию

Выбирается произвольна точка

- Находятся все точки, удаленные от стартовой точки на расстоянии, не превышающем радиус окрестности eps.
- Если множество точек, находящихся в пределах радиуса окрестности eps, меньше значения min_samples, стартовая точка помечается как шум (noise)
- Если это множество точек больше значения min_samples, стартовая точка помечается как ядровая и ей назначается метка нового кластера.
- Затем посещаются все соседи этой точки (находящиеся в пределах eps). Если они еще не были присвоены кластеру, им присваивается метка только что созданного кластера. Если они являются ядровыми точками, поочередно посещаются их соседи и т.д.

Кластер растет до тех пор, пока не останется ни одной ядерной точки в пределах радиуса окрестности eps. Затем выбирается другая точка, которая еще не была посещена, и повторяется та же самая процедура.

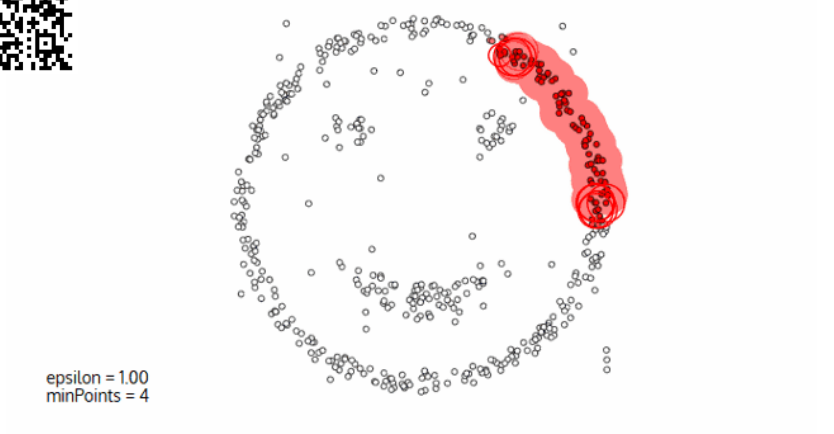

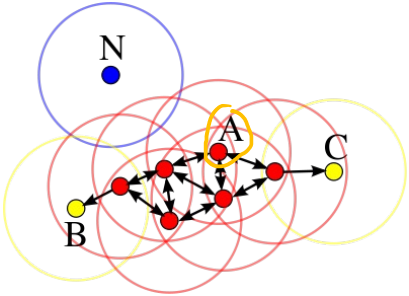

https://www.naftaliharris.com/blog/visualizing-dbscan-clustering/
https://cdn-images-1.medium.com/max/640/1*tc8UF-h0nQqUfLC8-0uInQ.gif

ВТОБ | ОТКРЫТОЕ ОБРАЗОВАНИЕ

Плюсы и минусы DBSCAN

Плюсы:

+ сам определяет количество кластеров

+ выделяет сложные формы кластеров

+ находит выбросы

Минусы:

- выбор параметров

- плохо выделяет кластеры с разной плотностью

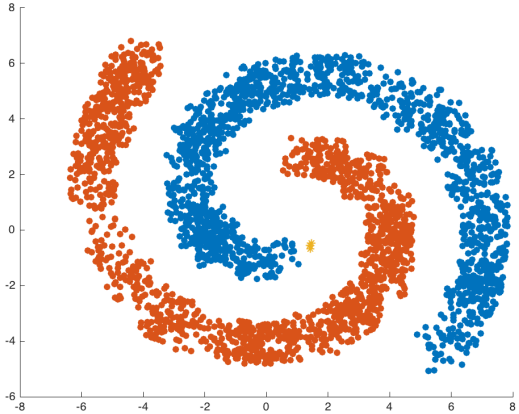

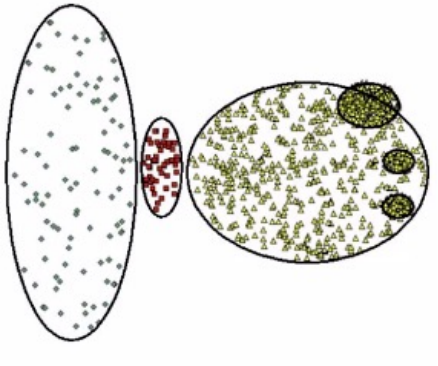

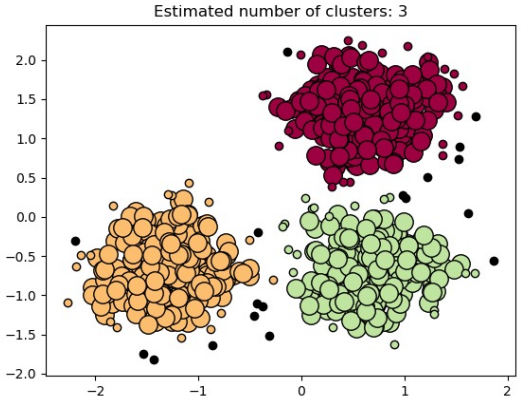

Силуэтный коэффициент

Силуэтный коэффициент

Показывает, насколько среднее расстояние до объектов своего кластера отличается от среднего расстояния до объектов других кластеров.

$$s = \frac{b - a}{max(a, b)}$$

a — среднее расстояние от данного объекта до объектов из того же кластера

b — среднее расстояние от данного объекта до объектов из другого ближайшего кластера

Диапазон коэффициента: [-1,1]

-1 – худший вариант, разрозненная кластеризация

0 – кластеры пересекаются и накладываются

1 – лучший вариант, четко выделенные кластеры

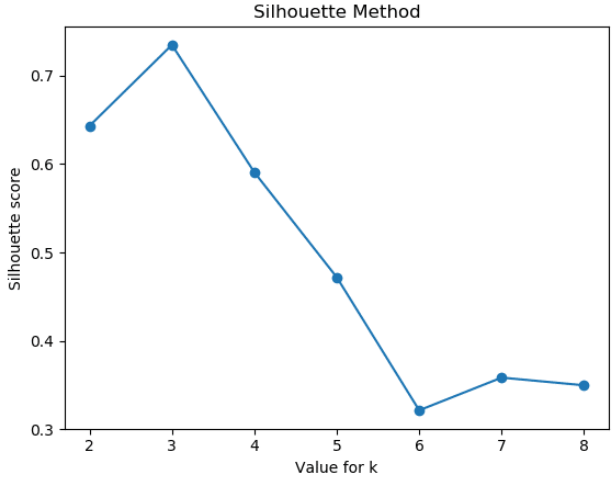

Сравнение кластеризации

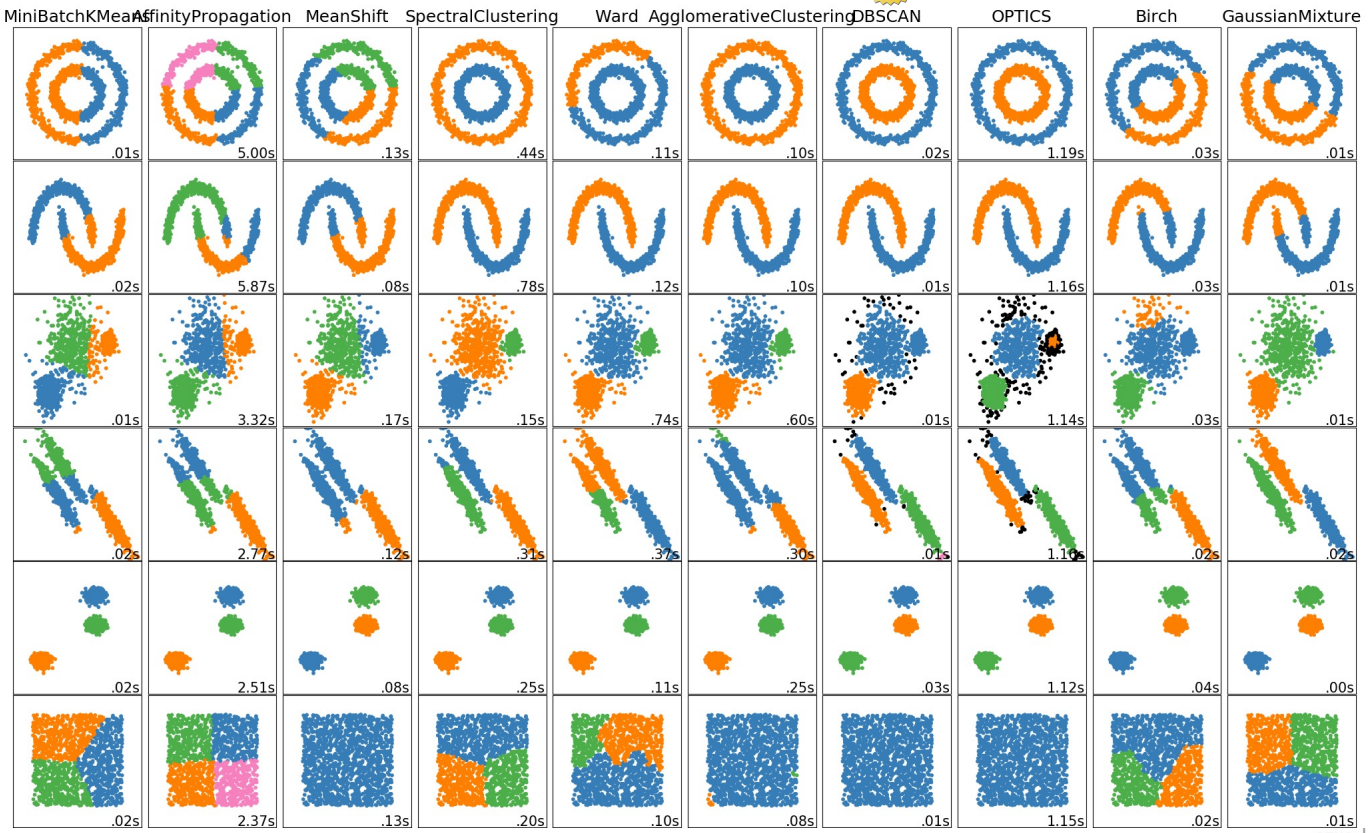

https://scikit-learn.org/stable/modules/clustering.html

Практика

Дополнительные матриалы

Обзор кластеризации из библиотеки sklearn:
https://scikit-learn.org/stable/modules/clustering.html
https://scikit-learn.org/stable/modules/clustering.html#hierarchical-clustering
https://scikit-learn.org/stable/modules/clustering.html#dbscan

Силуэтный коэффициент из библиотеки sklearn:
https://scikit-learn.org/stable/modules/clustering.html#silhouette-coefficient

Визуализация DBSCAN:
https://www.naftaliharris.com/blog/visualizing-dbscan-clustering/

Проверка достижения целей

Проверка достижения целей

Как работает иерархическая кластеризация?

Как работает DBSCAN?

Какие метрики качества кластеризации?
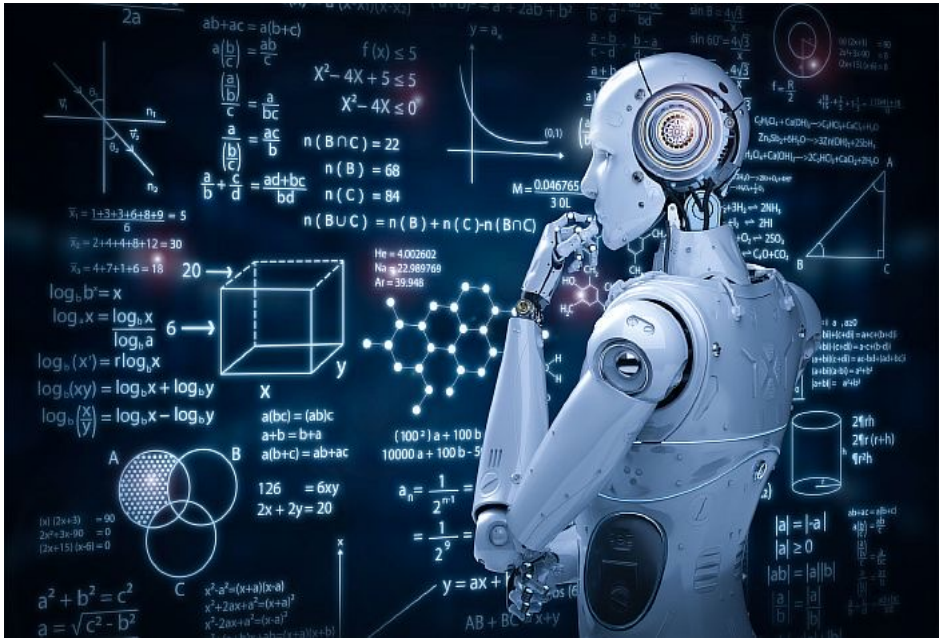
Какой алгоритм кластеризации лучше всех?